УДК 004.032.26

НЕЙРОСИСТЕМА ДИАГНОСТИКИ ЗАБОЛЕВАНИЙ КОЖИ

Доля Юлия Григорьевна, Кубанский государственный университет, 350040, Российская Федерация, г. Краснодар, ул. Ставропольская, 149.

бакалавр, ORCID: 0009-0004-5570-2832, e-mail: juliadolya06@gmail.com

Лукащик Елена Павловна, Кубанский государственный университет, 350040, Российская Федерация, г. Краснодар, ул. Ставропольская, 149,

кандидат физико-математических наук, доцент, ORCID: 0000-0002-7900-0841, e-mail: lep_9091@mail.ru

Аннотация. Данная работа демонстрирует результаты применения сверточной нейронной сети при создании автоматизированной системы диагностики кожных заболеваний по их изображениям. На сегодняшний день архитектуры, основанные на сверточных сетях, являются лучшим решением для задач распознавания образов.

В ходе численного эксперимента подобраны параметры архитектуры сверточной сети, такие как: количество слоев, размерность ядра свертки для каждого из них и количество извлекаемых фильтров на слое, функция активации и другие, влияющие на качество обучения.

Большое внимание уделено этапу обучения сети: описаны необходимость и суть применяемых методов. Первичное обучение нейронной сети проводилось на данных открытого архива изображений ImageNet. Предобученная сеть была перенастроена на классификацию кожных заболеваний на подготовленном наборе данных, составленном из открытого датасета ISIC, и протестирована на контрольной выборке, исключенной из общего набора обучающих данных.

На контрольных выборках диагностический результат по метрике, отображающей способность сетевой модели давать правильный ответ относительно общего количества исследований, достиг 90%. Результат по метрике, объединяющей в себе информацию о точности и полноте, составил 89% и 91% для классов новообразований: меланомы (злокачественная) и невуса (доброкачественная) соответственно.

Ключевые слова: машинное обучение, распознавание образов, нейронная сеть, свертка, классификация, диагностика, новообразования, меланома, невус.

NEUROSYSTEM FOR DIAGNOSTICS OF SKIN DISEASES

Julia G. Dolya, Kuban State University, 350040, Russian Federation, Krasnodar, St. Stavropolskay, 149.

bachelor, ORCID: 0009-0004-5570-2832, e-mail: juliadolya06@gmail.com

Elena P. Lukashchik, Kuban State University, 350040, Russian Federation, Krasnodar, St. Stavropolskay, 149,

Ph.D. (Phys & Math), Associate Professor, ORCID: 0000-0002-7900-0841, e-mail: lep_9091@mail.ru

Abstract. This work demonstrates the results of using a convolutional neural network to create an automated diagnosing system for skin diseases by their images. Today, architectures based on convolutional networks are the best solution of image recognition problems.

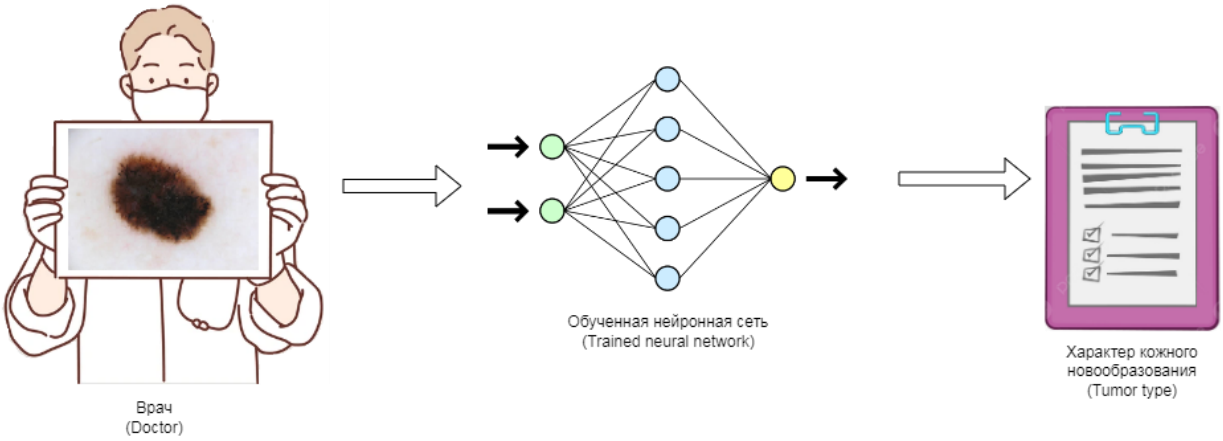
During the numerical experiment, the parameters of the convolutional network architecture were selected, such as: the number of layers, the dimension of the convolution kernel for each of them and the number of extracted filters per layer, the activation function and others that affect the quality of training.

Much attention is paid to network training. The necessity and essence of the methods used are described. Primary training of the neural network was carried out on data set from the open image archive ImageNet. Then the pre-trained network was reconfigured to classify skin diseases on a prepared data set compiled from the open ISIC dataset, and tested on a control sample excluded from the general training data set.

In control samples the diagnostic result reached 90% by the metric reflecting the ability of the network model to give the correct answer relative to the total number of studies. By the metric combining information on precision and recall the result was 89% and 91% for the classes of neoplasms: melanoma (malignant) and nevus (benign), respectively.

Keywords: machine learning, image recognition, neural network, convolution, classification, diagnosis, skin neoplasms, melanoma, nevus.

Graphical annotation (Графическая аннотация)



ВВЕДЕНИЕ

Несмотря на достигнутое за последние годы понимание международным сообществом серьезности глобальных экологических проблем, позволившее значительно сократить выбросы химикатов в атмосферу, озоновый слой разрушается. Истощение озонового слоя приводит к повышению уровня ультрафиолетового излучения, что является первопричиной раковых заболеваний кожи. Так, в связи с «увеличением суммарного времени и интенсивности воздействия УФ части спектра солнечного света на человека, генетически к этому неподготовленного», в современном мире наблюдается тревожная тенденция роста заболеваемости кожи [2]. В наше время каждый десятый страдает от заболеваний кожи. Самой злокачественной и агрессивной опухолью является меланома.

Однако диагностика заболеваний кожи значительно затруднена в связи с разнообразием видов и симптомов дерматологических заболеваний. Такая задача требует от врача-дерматолога глубоких знаний и навыков, отнимает много времени, и является достаточно трудоемкой. По этой причине дерматологам требуются годы обучения, чтобы развить навыки постановки точного диагноза. При формировании диагноза необходимо учитывать все особенности, наблюдаемые у пациента, и сравнивать их с особенностями, наблюдаемыми при различных заболеваниях. Известно, что точность правильного выявления кожных поражений врачом-дерматологом составляет менее 80%. На сегодняшний день развитие нейросетевых технологий компьютерного зрения позволяет автоматизировать процесс диагностики этого заболевания. Использование глубоких нейронных сетей позволяет повысить точность определения диагноза, ускорить и облегчить решение многих проблем. Данная работа демонстрирует разработку сверточной нейронной сети для диагностики кожных заболеваний, а именно для определения доброкачественных (невус) и злокачественных (меланома) новообразований кожи.

МОДЕЛЬ СИСТЕМЫ

Нейронная сеть – это метод в искусственном интеллекте, цель которого имитировать структуру и функциональность биологического мозга. Одним из лучших алгоритмов по распознаванию и классификации изображений является сверточная нейронная сеть – модель нейронных сетей глубокого обучения, предложенная Яном Лекуном [3]. Сверточная нейронная сеть позволяет создавать более сложные представления визуальных данных, так как по аналогии со зрительной корой головного мозга простые характеристики извлекаются на ранних стадиях, а более сложные характеристики изучаются на более глубоких уровнях.

Сверточные сети в зависимости от типа исследуемой задачи настраиваются так, чтобы найти лучший признак. Они обеспечивают масштабируемый подход к работе с изображениями, используя принципы линейной алгебры для выявления закономерностей между признаками объектов. Главная идея таких сетей состоит в том, что обработка участка изображения должна происходить независимо от его конкретного расположения.

Сверточная нейронная сеть состоит из нескольких слоев, которые можно условно разделить на три группы: сверточные слои, слои подвыборки и полносвязные слои. По мере прохождения данных через эти слои сложность сети увеличивается, что позволяет ей с каждым следующим слоем последовательно идентифицировать большие части изображения, что в конечном итоге приводит к распознаванию предполагаемого объекта. Объединение всех слоев составляет полную архитектуру сверточной нейронной сети. В основе разработанной системы лежит нейронная сеть с архитектурой ResNet-50 – наиболее популярной и эффективной моделью сверточных нейронных сетей в области обработки растровых изображений [4].

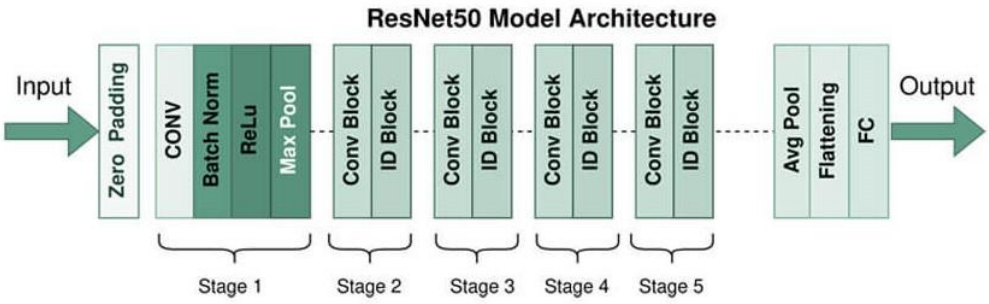


Рисунок 1 – Структура сети ResNet-50

ResNet-50 состоит из 50 слоев, разделенных на 5 блоков, каждый из которых содержит набор блоков с остаточными связями, которые позволяют модели обучаться на глубоких архитектурах, не сталкиваясь с проблемой затухания градиента. Остаточные блоки позволяют сохранить информацию из более ранних слоев, что помогает сети лучше изучить представление входных данных. Каждый остаточный блок состоит из двух сверточных слоев, за каждым из которых следует слой пакетной нормализации и функция активации ReLU. Затем выходные данные второго сверточного слоя добавляются ко входным данным остаточного блока, который затем передается через другую функцию активации ReLU. Выходные данные остаточного блока затем передаются следующему блоку. В архитектуре сети используется идея бутылочного горлышка. Остаточный блок с узким местом использует свертки 1×1, затем свертку 3×3, в конце возвращает количество карт свертками 1×1. Такая процедура позволяет быстрее обучать каждый слой.

СРЕДА РАЗРАБОТКИ СИСТЕМЫ

Для разработки и обучения нейронной сети выбран язык программирования Python, а конкретно его распространенная реализация CPython, написанная на C. Язык предлагает широкие возможности машинного обучения. Так же при работе с нейронными сетями немаловажную роль имеет предобработка входных данных для обучения. Для работы с данными Python предоставляет множество удобных библиотек.

Реализация описанной нейронной сети выполнена на основе фреймворка PyTorch. Он предоставляет широкий доступ для манипулирования низкоуровневыми деталями, что позволяет точнее настраивать параметры сети. Фреймворк позволяет переключается в коде между обычным центральным (CPU) и графическим процессором (GPU). Встроенный модуль Optim включает в себя реализации всех наиболее часто используемых инструменты оптимизации для работы нейронных сетей, что делает разработку модели эффективнее. Модуль Data Loader позволяет создавать мини-пакеты в рамках одного датасета и подгружать их в модель, перемешивать данные, определять размер мини-пакета, что упрощает и ускоряет загрузку данных, экономит память.

В работе использованы библиотеки Numpy, Scikit-learn и Seaborn. Scikit-Learn — популярная библиотека машинного обучения на Python [5]. Она предоставляет широкий спектр метрик для оценки качества работы обученной нейронной сети, а также позволяет вычислить матрицу ошибок, с помощью которой можно оценить сильные и слабые стороны модели. Библиотека Numpy использовалась для более эффективной работы с многомерными массивами и матрицами. Для визуализации данных применялась библиотека Seaborn.

ОБУЧЕНИЕ СВЕРТОЧНОЙ СЕТИ

Обучение нейронной сети обычно требует большого количества тренировочных данных, вычислительных ресурсов и времени. Однако сверточные нейронные сети имеют общее свойство: на первых слоях модели сеть пытается изучить общую для всех изображений информацию, такую как обнаружение краев, изменений интенсивности цвета и т. д. Такие признаки не являются специфичными для конкретного набора данных, так как не зависят от типа обрабатываемого изображения, по этой причине они могут быть применены и для решения другой задачи. В связи с этим в задачах компьютерного зрения, требующих большого объема данных и огромного количества вычислительных мощностей, наиболее часто используют Transfer learning и Fine-Tuning.

Transfer learning (перенос обучения) — это метод машинного обучения, применяющийся для настройки сети и ее обучения, при котором знания, полученные моделью в задаче с большим количеством доступных обучающих данных, применяются в новой задаче, в которой данных немного [6]. То есть вместо того, чтобы начинать процесс обучения сети с нуля, можно использовать значения весов, полученных в результате решения другой задачи. Другими словами, Transfer learning позволяет не проводить обучение нейронной сети с самого начала, а использовать в качестве основы готовую предварительно обученную сеть. Такой метод позволяет быстрее и эффективнее обучать новую нейронную сеть, а также может помочь предотвратить переобучение, поскольку модель уже усвоила общие признаки, которые могут оказаться полезными во второй задаче.

Обычно вместе с методом переноса обучения используется Fine-Tuning. Fine-Tuning (тонкая настройка обучения) — это один из методов, который позволяет адаптировать предварительно обученные модели нейронных сетей для конкретных задач или наборов данных. При тонкой настройке берутся существующие параметры сети и дополнительно обучаются для выполнения новой задачи. Одним из важных параметров сети является скорость обучения, определяющая процесс обновления весов во время обучения. Для тонкой настройки необходимо использовать меньшую скорость обучения, чем для обучения с нуля, чтобы сохранить знания, полученные с помощью предварительно обученной сети. Другим способом Fine-Tuning является заморозка и разморозка некоторых слоев модели. Замораживание слоя означает, что его веса не обновляются во время обучения. Обычно в новой сети замораживаются только те слои исходной модели, знания которых должны быть сохранены для нового обучения. Последние слои, фиксирующие более конкретные признаки объектов, участвуют в обучении. Также для адаптации к новой задаче к модели можно добавлять новые слои. Например, добавление выходного слоя, соответствующего количеству классов новой задачи. В качестве тонкой настройки для

улучшения способности модели к обобщению используют аугментацию данных, состоящую в применении некоторых преобразований к данным для увеличения их разнообразия и надежности.

Обучение нейронной сети ResNet-50 проводилось на данных открытого архива изображений ImageNet [7]. Предварительно обученная сеть была перенастроена на классификацию кожных заболеваний. В стандартном варианте сети ResNet-50 последний уровень полносвязного слоя предназначен для классификации 1000 классов (количество классов в ImageNet). В исследуемой задаче диагностики заболеваний кожи количество классов отличается от того, которое было в исходном датасете. Так как для распознавания предоставлено два объекта (меланома и невус), то это задача бинарной классификации, то есть на выходе сети должен быть один нейрон. По этой причине от сети ResNet-50, натренированной на определенную задачу, была взята сверточная часть, выделяющая характерные признаки изображения, а часть классификации была заменена на другую, состоящую из полносвязного слоя и имеющую на выходе один нейрон. Такая замена последнего слоя в архитектуре ResNet-50 позволяет использовать уже полученные знания для решения более конкретной задачи. Для интерпретации выходов сети как вероятностей распознаваемых классов последний слой новой сети представлен функцией активации softmax с двумя классами [8]. В слое softmax количество узлов равно количеству выходов, а значение показывает вероятность каждого выхода.

В архитектурах глубоких нейронных сетей начальные слои изучают общую информацию, а слои на последнем уровне более специфичные признаки. Данные сформированного для задачи датасета сильно отличаются от архива, на котором обучалась ResNet-50. По этой причине использовался метод Fine Tuning, который захватывает несколько последних сверточных слоев. Чем сильнее исходные данные отличаются от тех, на которых нейронная сеть обучалась, тем большее количество слоев необходимо разморозить. Так, перед обучением разработанной сети были разморожены веса последних 10 слоев, чтобы они тоже участвовали в обучении.

На следующем этапе для правильной корректировки весов была выбрана небольшая начальная скорость обучения. В качестве функции потерь использовалась функция Кросс-энтропия (перекрестная энтропия) [9], которая является более динамичной и устойчивой по сравнению с другими метриками, так как учитывает статистическую достоверность и различия в атрибутах данных. Для изменения весов и скорости обучения применялся оптимизатор Adam, обновляющий скорость обучения для каждого веса нейронной сети индивидуально.

Данные для обучения реализуемой сети были взяты из наиболее популярного архива кожных заболеваний ISIC [10], находящегося в открытом доступе и состоящего из изображений меланом и невусов. В сверточных нейронных сетях обычно используется обучение с учителем. Обучение с учителем предполагает наличие полного набора размеченных данных для тренировки модели на всех этапах ее построения [11]. По этой причине исходный датасет был разделен на три части: обучающую, валидационную и тестовую выборки. Каждая выборка была разделена на две категории – меланома и невус. Обучение сети проводилось на обучающей выборке, составляющей около 70% от всех имеющихся данных, подбор оптимального набора гиперпараметров, а также контроль за переобучением проводился на валидационной выборке (15% процентов наблюдений). Для оценки качества работы модели использовалась тестовая выборка (также 15% процентов наблюдений). Однако изображений в архиве оказалось недостаточно для качественного обучения модели. Кроме того, многие изображения в этом архиве содержат различные зашумления (волосы, разметка на коже, плохое освещение, разная масштабируемость). Совокупность таких обстоятельств затрудняет процесс качественного обучения нейронных сетей [12].

Необходимо отметить, что полученный набор данных является несимметричным: количество изображений меланом значительно меньше количества изображение невусов.

Это обусловлено естественными причинами, так как случаи установления диагноза меланомы встречаются реже в общем количестве дерматологических осмотров. Поэтому была проведена стратификация – балансировка классов в выборке. Таким образом получен датасет порядка 17 тысяч изображений.



Рисунок 2 – Примеры изображений из датасета

По совокупности причин применен метод аугментации данных на лету. Проводилась модификация данных из тренировочной и валидационной выборки и создание на этой основе дополнительных изображений. Тестовая выборка оставалась неизменной. Было важно задать параметры аугментации так, чтобы они подходили к рассматриваемой задаче. Неправильно подобранные параметры привели бы к искажению изображений и снижению точности работы сети. Поэтому в качестве модификации использовались операции поворота изображений на определенный угол, отображение по горизонтали или вертикали. Такие изменения являются стандартными и хорошо подошли к задаче, так как не влияют на главные признаки объекта.

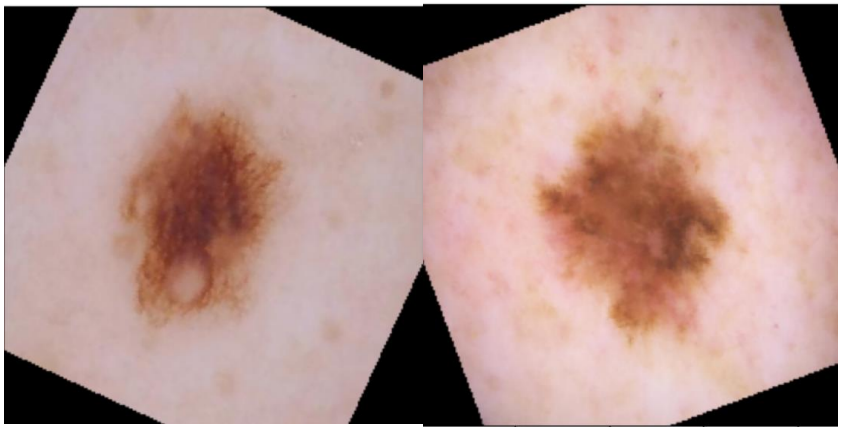


Рисунок 3 – Применение аугментации данных

RGB-значения полученных объектов будут находиться в разных местах трехмерного изображения, то есть тензорное представление будет другим, что повышает обобщающую способность сети. Такие изменения позволили привести все изображения к одному размеру, а также увеличить объем исходного количества изображений в тренировочном датасете в два раза.

Предобученная нейронная сеть дополнительно обучена на подготовленном тренировочном наборе данных. Оценка работы сети проведена на тестовом датасете, содержащем данные, не участвующие при обучении.

ОЦЕНКА КАЧЕСТВА РАБОТЫ СЕТИ

Для оценки качества обученной нейронной сети, а также для сравнения результатов работы алгоритмов машинного обучения используют численные меры, или метрики. Метрику обычно измеряют на тестовом датасете, содержащем данные, не участвующие в

обучении сети. Существует множество метрик, предназначенных для задач разных категорий, таких как задачи классификации, регрессии, ранжирования, обработки естественного языка и т. д.

В случае бинарной классификации для каждого объекта возможны следующие исходы распознаваний [13]:

1) истинно-положительные (True Positive, TP) – класс, предсказанный как положительный, является положительным;

2) истинно-отрицательные (True Negative, TN) – класс, предсказанный как отрицательный, является отрицательным;

3) ложноположительные (False Positive, FP) – класс, предсказанный как положительный, является отрицательным;

4) ложноотрицательные (False Negative, FN) – класс, предсказанный как отрицательный, является положительным.

Для наглядности эти исходы представляют в виде двумерной таблицы, которая называется матрицей ошибок [14]. В матрице ошибок строки представляют экземпляры истинного класса, а столбцы — прогнозируемого класса.

	Predicted: NO	**Predicted: YES**
Actual: NO	TN	FP
Actual: YES	FN	TP

Рисунок 4 – Матрица ошибок

На основе комбинаций элементов матрицы ошибок строятся метрики, позволяющие детальнее оценить полноту, чувствительность и точность нейронной сети.

Самой простой и распространенной является метрика accuracy – количество верно классифицированных объектов среди всех объектов экземпляра [15].

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

Однако в случае несбалансированных по классам данных она мало информативна, так как не учитывает соотношения ложных срабатываний модели.

В случае асимметрии классов, когда необходимо оценить качество работы нейронной сети на каждом классе в отдельности, используются метрики precision, recall, F1. Метрика precision показывает количество истинно положительных объектов из всего набора положительных объектов. Её значения варьируются в диапазоне от 0 до 1. Результат precision должен быть максимально высоким. Оценка точности, равная 1, будет означать, что нейронная сеть способна хорошо классифицировать правильную и неправильную маркировку классов, так как она не упустила ни одного истинного положительного результата. Недостатком такой метрики является то, что она не учитывает ложноотрицательные результаты.

$$\text{precision} = \frac{TP}{TP + FP} \quad (2)$$

В отличие от precision метрика recall показывает долю истинно положительных объектов среди всех объектов положительного класса, не учитывая при этом ложноположительные результаты. Метрику recall также часто называют полнотой или чувствительностью нейронной сети.

$$\text{recall} = \frac{TP}{TP + FN} \quad (3)$$

В случае, когда метрики precision и recall одинаково значимы, можно использовать их среднее гармоническое [16]. Такая оценка называется F1-мерой. Она достигает своего наилучшего значения в 1 и худшего в 0.

$$\mathrm{F1} = 2 * \frac{\mathrm{precision} * \mathrm{recall}}{\mathrm{precision} + \mathrm{recall}} \quad (4)$$

Качество применяемой в диагностической системе сверточной сети измерялось по разным метрикам на тестовом датасете, состоящем из 571 изображения. Результат по метрике Accuracy, отображающей способность модели давать правильный ответ относительно общего количества исследований, составил 90%. Результат по метрике F1, объединяющей в себе информацию о точности и полноте, составил 89% и 91% для класса меланомы и невуса соответственно.

ЗАКЛЮЧЕНИЕ

Результаты исследования доказали удачность подобранных параметров сети и успешность сверточных нейронных сетей для диагностики кожных новообразований на основе их изображений.

Так, выбор сверточной архитектуры нейронных сетей обеспечил системе следующие преимущества:

1) гораздо меньшее число настраиваемых весов, по сравнению с полносвязными сетями, связанное с использованием ядра свертки для всего изображения, благодаря чему не нужно для анализа разных фрагментов изображения отводить свои собственные веса;

2) возможность удобного распараллеливания вычислений, а значит и перенос нагрузки при обучении сети на графический процессор;

3) возможность обучения сети обычным методом обратного распространения ошибки, по аналогии с другими сетями;

4) относительная устойчивость алгоритма к сдвигу и повороту распознаваемого изображения.

Актуальность данной работы состоит в том, что она демонстрирует возможности обучения сети даже на изображениях с разным качеством, на которых объект представляет собой сложный визуальный образ и может плохо выделяться на фоне окружения.

Разработанная модель нейронной сети может использоваться в качестве основы для создания встроенных систем, WEB- и мобильных приложений, которые, в свою очередь, могут быть применены для оказания первичной медицинской помощи, в том числе и доврачебной. Также она может применяться медицинскими работниками как вспомогательное средство в принятии решений во время диагностики кожных заболеваний по фотографиям.

Для дальнейшего совершенствования нейронной сети и повышения точности ее работы необходимо увеличить объем обучающей и валидационной выборок, так как несбалансированный датасет, а также отсутствие достаточного количества примеров определенных видов меланом может привести к ошибкам в распознавании моделью кожных заболеваний в реальных условиях.

Список источников

1. Соробин, А. Б. Сверточные нейронные сети: примеры реализаций / А. Б. Соробин. – Москва : РТУ МИРЭА, 2020. – 159 с.

2. Ганцев, Ш. Х. Онкология : учебник / Ш. Х. Ганцев. – Москва : Гэотар-Медиа, 2023. – 704 с.

3. Ростовцев, В. С. Искусственные нейронные сети: Учебник для вузов / В. С. Ростовцев. – СПб.: Лань, 2021. – 216 с.

4. Resnet. – Режим доступа: https://neurohive.io/ru/vidy-nejrosetej/resnet-34-50-101/ свободный. – Заглавие с экрана. – Яз. рус. (дата обращения: 03.09.2024).

5. Рашка, С. Python и машинное обучение / С. Рашка, В. Мирджалили. – СПб.: Диалектика, 2021. – 848 с.
6. Ферлитш, Э. Шаблоны и практика глубокого обучения / Э. Ферлитш. – Москва : ДМК Пресс, 2022. – 538 с.
7. ImageNet. – Режим доступа: https://www.image-net.org/ свободный. – Заглавие с экрана. – Яз. англ. (дата обращения: 04.09.2024).
8. Данилов, В. В. Нейронные сети : учебное пособие / В. В. Данилов. с Донецк : ДонНУ, 2020. – 158 с.
9. Баланов, А. Н. Машинное обучение и искусственный интеллект: Учебник для вузов / А. Н. Баланов. – СПб.: Лань, 2024. – 172с.
10. ISIC. – Режим доступа: https://www.isic-archive.com/ свободный. – Заглавие с экрана. – Яз. англ. (дата обращения: 04.09.2024).
11. Сапрыкин, О. Н. Интеллектуальный анализ данных: учебное пособие / О. Н. Сапрыкин. – Самара : Самарский университет, 2020. – 80 с.
12. Колмогорова, С. С. Обработка данных алгоритмами искусственного интеллекта в системе интернета вещей / С. С. Колмогорова. – Санкт-Петербург : Лань, 2023. – 104 с.
13. Пальмов, С. В. Системы и методы искусственного интеллекта: учебное пособие / С. В. Пальмов. – Самара : ПГУТИ, 2020. – 191 с.
14. Tharwat A. Classification assessment methods // Applied Computing and Informatics. 2021. Vol. 17, no. 1. P. 168–192.
15. Метрики в машинном обучении. – Режим доступа: https://neptune.ai/blog/performance-metrics-in-machine-learning-complete-guide свободный. – Заглавие с экрана. – Яз. англ. (дата обращения: 06.09.2024).
16. Бинарная классификация. – Режим доступа: https://www.learndatasci.com/glossary/binary-classification/ свободный. – Заглавие с экрана. – Яз. англ. (дата обращения: 05.09.2024).

References

1. Sorobin, A. B. Svertochnye nejronnye seti: primery realizacij [Convolutional Neural Networks: Examples of Implementations]. Moscow, RTU MIREA, 2020. 159 p.
2. Gancev, S. H. Onkologiya: uchebnik [Oncology: textbook]. Moscow, Geotar-Media, 2023. 704 p.
3. Rostovcev, V. Iskusstvennye nejronnye seti: Uchebnik dlya vuzov [Artificial Neural Networks: textbook for universities]. Saint Petersburg, Lan, 2021. 216 p.
4. Resnet. Available at: https://neurohive.io/ru/vidy-nejrosetej/resnet-34-50-101/ (accessed 03.09.2024).
5. Rashka, S. Python i mashinnoe obuchenie [Python and Machine Learning]. SPb, Dialektika, 2021. 848 p.
6. Ferlitsh, E. SHablony i praktika glubokogo obucheniya [Deep Learning Patterns and Practices]. Moscow, DMK Press, 2022. 538 p.
7. ImageNet. Available at: https://www.image-net.org/ (accessed: 04.09.2024).
8. Danilov, V. V. Nejronnye seti : uchebnoe posobie [Neural networks : a textbook]. Donetsk, DonNU, 2020. – 158 p.
9. Balanov, A. N. Mashinnoe obuchenie i iskusstvennyj intellekt: Uchebnik dlya vuzov [Machine learning and artificial intelligence: Textbook for universities]. Saint Petersburg, Lan, 2024. 172 p.
10. ISIC. Available at: https://www.isic-archive.com/ (accessed 04.09.2024).
11. Saprykin, O. N. Intellektualnyj analiz dannyh: uchebnoe posobie [Data Mining: a textbook]. Samara, Samara University, 2020. 80 p.
12. Kolmogorova, S. S. Obrabotka dannyh algoritmami iskusstvennogo intellekta v sisteme interneta veshchej [Data processing by artificial intelligence algorithms in the Internet of Things system]. Saint Petersburg, Lan, 2023. 104 p.

13. Palmov, S. V. Sistemy i metody iskusstvennogo intellekta: uchebnoe posobie [Artificial Intelligence systems and methods: a textbook]. Samara, PGUTI, 2020. 191 p.
14. Tharwat A. Classification assessment methods // Applied Computing and Informatics. 2021;17(1):168–192.
15. Metrics in Machine Learning. Available at: https://neptune.ai/blog/performance-metrics-in-machine-learning-complete-guide (accessed: 05.09.2024).
16. Binary Classification. Available at: https://www.learndatasci.com/glossary/binary-classification/ (accessed: 05.09.2024).

Статья поступила в редакцию ; одобрена после рецензирования ; принята к публикации .
The article was submitted ; approved after reviewing ; accepted for publication .