УДК 004.81

РАЗРАБОТКА НЕЙРОСИСТЕМЫ РАСПОЗНАВАНИЯ РЕЧИ

Ю. Г. Доля, Е. П. Лукащик

Кубанский государственный университет

ул. Ставропольская 149, 350040, Краснодар, Россия

Ключевые слова: чтение по губам, визуальное распознавание речи, нейронная сеть, глубокое обучение, видеопоследовательность.

Аннотация. В работе предлагается решение проблемы распознавания речи по движениям губ с использованием нейронных сетей. Предложена архитектура, состоящая из трехмерной сверточной сети и двунаправленной рекуррентной сети. Для подготовки датасета выполнена предварительная обработка видеоданных, включающая выделение области губ и формирование последовательности кадров. Оценка качества модели проводилась с использованием метрик CER и WER.

Введение. В современном мире большое распространение получили системы распознавания речи по аудио, однако их недостатком является ограниченность использования в условиях шума, при искажении звукового сигнала, а также при взаимодействии с людьми с нарушениями речи или слуха. По этой причине особое значение приобретают методы визуального распознавания речи на основе артикуляционных движений губ. Такой способ позволяет восстанавливать содержание речи без использования звукового сигнала, применять подобные системы в неблагоприятных акустических условиях, а также в ассистивных технологиях. Несмотря на важный потенциал, чтение по губам остается сложной задачей из-за наличия различных речевых единиц, которые имеют практически идентичное визуальное представление [1]. При этом процесс обучения человека чтению по губам является длительным и трудоемким, а точность распознавания

даже у обученных специалистов оказывается ниже точности аудиального восприятия. Это обуславливает растущую на сегодняшний день необходимость разработки автоматизированных системы визуального распознавания речи.

Разработка модели распознавания речи по губам. Визуальное распознавание речи (чтение по губам) – задача восстановления речевого содержания на основе анализа артикуляционных движений. К числу основных факторов, усложняющих речевое восприятие, относятся индивидуальные особенности произношения, различия в артикуляции, темпе речи. Также визуальное распознавание речи отражает только внешние аспекты артикуляции. Большая часть артикуляционных движений, связанных с положением языка, мягкого неба и других элементов речевого аппарата, играющих важную роль в формировании звуков, остается скрытой. Это накладывает ограничения на точность чтения речи по губам.

Для обучения модели использовался датасет GRID. Он включает в себя видео с дикторами, которые произносят фразы на английском языке, построенные по определенной структуре. Датасет отличается высоким качеством данных, однако из-за заданного шаблона фраз не отражает структуру естественной разговорной речи, поэтому для получения обучающих примеров из исходных предложений были выделены отдельные слова. Но при формировании итогового датасета применялись не все представленные слова, из выборки были исключены предлоги и отдельные буквы. Это связано с их малой временной протяженностью и низкой артикуляционной информативностью. Так, был сформирован словарь из 22 слов, общий объем датасета составил 132 тыс. обучающих примеров.

Для выделения фрагментов с обучающими примерами из исходных видеозаписей с помощью утилиты MFA были определены временные границы начала и окончания каждого слова. При этом в естественной речи слова не произносятся изолированно друг от друга, что приводит к

появлению коартикуляции, то есть наложению одного звука на другой при разговоре. Нарезка фрагментов строго по временным границам может привести к изменению произношения слова. По этой причине при формировании обучающих примеров к временным меткам добавлялся интервал 0,1 секунды.

Собранные видео были разбиты на кадры с частотой 25 fps. Для каждого кадра с помощью MediaPipe находилась и вырезалась область интереса. На начальном этапе подготовки датасета в качестве области интереса рассматривалась только зона губ. Однако в ходе анализа выяснилось, что при таком способе часть важной информации об артикуляции теряется. Хотя губы и являются основным визуальным компонентом артикуляции, речь складывается в результате взаимодействия нескольких анатомических частей лица. Например, положение нижней челюсти указывает на степень раскрытия рта, движение щек – на его округление или растяжение. Так, для области идентификации были выбраны координаты, соответствующие подбородку, части щек и основанию носа. Затем полученные кадры приводились к фиксированному размеру 96 на 96.

Архитектура разработанной модели состоит из трехмерной сверточной нейронной сети (3D CNN), двунаправленной LSTM, полносвязного слоя и CTC декодирования на выходе. 3D CNN используется для извлечения пространственно-временных признаков артикуляции [2]. Это означает выделение не только формы губы, но и изменений их артикуляции в процессе речи, что включает открытие губ, смыкание и другие переходы между артикуляционными позициями. В модели использовалось четыре 3D-сверточных блока, включающих трехмерную свертку, слой нормализации, функцию активации Relu и операцию MaxPooling. При этом операция пулинга выполнялась по пространственным измерениям, то есть высоте и ширине кадра, а временная размерность оставалась без изменений, что позволило сохранить информацию о

динамике движения губ. После сверточных блоков для уменьшения и согласования размерности признаков применялись слой адаптивного пространственного усреднения и линейная проекция признаков. На основе полученных признаков LSTM моделирует временные зависимости для анализа артикуляционных изменений [3]. Речь – это сложный процесс, в котором каждый звук определяется как предыдущими, так и последующими элементами. По этой причине была выбрана двунаправленная LSTM, так как она позволяет учитывать контекст в обоих направлениях. Рекуррентная часть модели состоит из двух слоёв LSTM. Для получения предсказаний на выходе сети использовался полносвязный слой с функцией активации LogSoftmax.

В задаче чтения речи по губам отсутствует точное покадровое соответствие между входной последовательностью кадров и целевой меткой. Это связано с тем, что количество кадров, как правило, превышает количество символов. Также длительность произнесения одного и того же слова разными дикторами может отличаться. Поэтому в качестве функции потерь при обучении сети была выбрана CTC. Для декодирования предсказаний модели был выбран метод greedy decoding.

Для повышения обобщающей способности сети к обучающей выборке применялись методы аугментации данных, а именно изменение контрастности и насыщенности изображений. Для обучения использовались оптимизатор Adam, планировщик скорости обучения OneCycleLR и методы регуляризации (ранняя остановка, слои Dropout, L2-регуляризация).

Оценка качества работы модели проводилась на тестовой выборке, состоящей из 13 тысяч примеров, с использованием двух метрик [4]. По метрике CER результат составил 14,18%. Это означает, что 14% символов было распознано неверно. Значение метрики WER составило 23,77%, то есть 24% слов было распознано неверно. Таким образом, 76% слов было распознано полностью корректно. Многие ошибки модели связаны с

пропуском или заменой одного символа. Это говорит о том, что модель правильно распознает структуру слова. Подобные ошибки можно считать незначительными, так как они могут быть исправлены с использованием языковой модели или словарной коррекции.

Заключение

Представленный прототип разработан для использования в системах, ориентированных на улучшение функциональных возможностей людей с инвалидностью и ограниченными возможностями здоровья. Результаты исследования подтвердили возможность применения нейронных сетей для визуального распознавания речи. Подготовлен датасет для обучения разработанной нейросетевой модели, апробация проведена по стандартным метрикам CER и WER. Определены направления повышения точности разработанной модели, требующие расширения словаря и совершенствования архитектуры нейронной сети.

Библиографический список

1. Мясоедова, М.А. Дистанционное обучение как современный формат совершенствования навыка чтения с губ (на базе корпуса омовизем) / М.А. Мясоедова, З.П. Мясоедова // Современные информационные технологии и ИТ-образование. – 2022. – Т. 18, № 2. – С. 374-382.

2. Ма, К. Трехмерное глубокое обучение на Python : руководство / К. Ма, В. Хегде, Л. Йольан; перевод с английского А. В. Логунова. – Москва: ДМК Пресс, 2023. – 226 с. – ISBN 978-5-93700-202-0.

3. Mienye, I.D. Recurrent Neural Networks: A Comprehensive Review of Architectures, Variants, and Applications / I. D. Mienye, T. G. Swart, G. Obaido // Information. – 2024. – Vol. 15, № 517. – P. 310-323.

4. Evaluation metrics for ASR : [сайт]. – URL: https://huggingface.co/learn/audio-course/ru/chapter5/evaluation (дата обращения: 17.03.2026).